

Regression

La **régression** est une technique de **statistique et de machine learning** qui permet de **modéliser la relation entre une variable dépendante (ou cible) et une ou plusieurs variables indépendantes (ou explicatives)**. En termes simples, elle sert à **prédire une valeur numérique à partir de données connues**.


Application 1 : Prédiction du prix d'une maison en fonction de sa surface

```
import pandas as pd
```

1. lire la data frame

```
[7] ✓ 0s df = pd.read_excel("prix_maison1.xlsx")
```

Afficher la dataframe



The screenshot shows a Jupyter Notebook interface. On the left, there is a sidebar with a grid icon and a dropdown menu. The main area displays a DataFrame named 'df' with two columns: 'area' and 'price'. The data is as follows:

	area	price
0	100	1218000
1	120	1440000
2	150	1800000
3	260	2860000
4	320	2880000

Below the table, there are two buttons: "Generate code with df" and "New interactive sheet".

Afficher shape (lignes,colonnes)

```
[8] df.shape
✓ 0s
... (5, 2)
```

- Le dataset contient 5 lignes et 2 colonnes

Afficher les infos de ma dataframe (types donnees, non-null et null cellules)

```
[ ] df.info()
✓
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5 entries, 0 to 4
Data columns (total 2 columns):
#   Column  Non-Null Count  Dtype
---  ---
0    area    5 non-null        int64
1   price    5 non-null        int64
dtypes: int64(2)
memory usage: 212.0 bytes
```

les statistiques : .T (transposition les lignes deviens des colonnes dans l'affichage)

Resumé statistique

```
[ ] df.describe().T
✓
```

	count	mean	std	min	25%	50%	75%
area	5.0	190.0	95.393920	100.0	120.0	150.0	260.0
price	5.0	2039600.0	786015.775923	1218000.0	1440000.0	1800000.0	2860000.0

- Les deux variables area et price sont de type numérique
- Il y a 5 valeurs pour chaque variable. Ce qui montre qu'il n'y a pas de valeurs manquante

2. Verification des valeurs manquantes :